

2025



Профайлинг пользователей ВКонтакте по их образовательным интересам

Разработка методологии
и сервиса для анализа
цифровых следов

СОДЕРЖАНИЕ

I. ПРОГРАММА ИССЛЕДОВАНИЯ

- ЦЕЛЬ ИССЛЕДОВАНИЯ
- АКТУАЛЬНОСТЬ ТЕМЫ
- ПРАКТИЧЕСКАЯ ЗНАЧИМОСТЬ ИССЛЕДОВАНИЯ

II. ПРОЦЕСС РАЗРАБОТКИ СЕРВИСА

СБОР ДАННЫХ

- ДАННЫЕ И РУЧНАЯ РАЗМЕТКА

МОДЕЛИ И АЛГОРИТМЫ

- ВЫБРАННЫЕ МЕТОДЫ И ПОДХОДЫ
- PIPELINE ОБРАБОТКИ ДАННЫХ
- ЛУЧШАЯ МОДЕЛЬ. МЕТРИКИ
- ОЦЕНКА КАЧЕСТВА МОДЕЛИ

АРХИТЕКТУРА СИСТЕМЫ

- WORKFLOW СИСТЕМЫ
- ОСНОВНЫЕ МОДУЛИ И ТЕХНОЛОГИЧЕСКИЙ СТЕК


III. ИНТЕГРАЦИЯ И ЗАПУСК СЕРВИСА

- ИНТЕГРАЦИЯ КОМПОНЕНТОВ
- VK API И ПАРСЕР
- ЗАПУСК И РАБОТА TELEGRAM-БОТА

IV. ВЫВОДЫ И ПЕРСПЕКТИВЫ

- ИТОГИ ПРОЕКТА
- ПЕРСПЕКТИВЫ И НАПРАВЛЕНИЯ РАЗВИТИЯ
- ПРИМЕР РАБОТЫ СЕРВИСА
- НАША КОМАНДА

2025



Программа исследования

ЦЕЛЬ ИССЛЕДОВАНИЯ

Верхнеуровневый процесс разработки профайлинга образовательных интересов



Наши цели:

- Разработка и апробация методологии для модели профайлинга образовательных интересов пользователей ВКонтакте
- Создание технического задания для прототипа сервиса, реализующего данную методологию. Разработка прототипа сервиса

АКТУАЛЬНОСТЬ ТЕМЫ



ВКОНТАКТЕ

одна из самых популярных социальных сетей в России и СНГ
(более 100 млн активных пользователей)



СОЦИАЛЬНЫЕ СЕТИ

ценный источник информации о предпочтениях и интересах пользователей



ПЕРСОНАЛИЗАЦИЯ ОБРАЗОВАНИЯ

растущий тренд, требующий точного определения образовательных интересов



ВОЗМОЖНОСТИ

таргетированные предложения, анализ трендов, персонализация траекторий

ПРАКТИЧЕСКАЯ ЗНАЧИМОСТЬ ИССЛЕДОВАНИЯ

СОЗДАНИЕ СЕРВИСА ПРОФАЙЛИНГА

Автоматическое определение образовательных интересов пользователей.

ТАРГЕТИРОВАНИЕ ОБРАЗОВАТЕЛЬНОГО КОНТЕНТА

Эффективное продвижение курсов, вебинаров, образовательных программ.

АНАЛИЗ ОБРАЗОВАТЕЛЬНЫХ ТРЕНДОВ

Выявление актуальных направлений и корректировка образовательных программ.

ПРИМЕНЕНИЕ

В онлайн-образовании, маркетинге, HR и исследовательской деятельности.

2025



Процесс разработки сервиса

Сбор данных



Данные и ручная разметка

Мы собрали информацию об:

- **44 333** пользователей
- **507 067** их подписок

Разметили вручную:

- **3574** групп
- **74** тематики
- **9** кластеров

Ручная разметка позволила обеспечить высокое качество обучающей выборки для моделей

Пример разметки:

193216804	Lotur Norm	Художник	https://t.me/lotur_norm \t(Заказы на арты откр...	0.231493	живопись	Искусство и культура
57335889	Deidra Lissa~	Художница	Добро пожаловать :3\tМеня зовут Екатерина Лисс...	0.165119	живопись	Искусство и культура
196667249	очень приятно, хан	Рыбалка	NaN	0.928999	охота и рыбалка	Сельское хозяйство
188968626	Мозыкин Дом	Художник	Доброго времени суток, Дорогой Путник! ❤️\tMe...	0.183097	хобби и увлечения	Общие интересы
60785982	balisangre	Художница	на заказ не рисую. Вообще. И эскизы для тату т...	0.209089	общение	Общие интересы



Модели и алгоритмы




Выбранные методы и подходы



Sentence Embeddings (NLP)

Модели
SentenceTransformer
(RoBERTa, SBERT,
LaBSE, multilingual-E5)




Модели классификации

Logistic Regression,
Random Forest,
SVM (линейное
и RBF-ядро)

Почему выбран этот подход?

- SentenceTransformer — современные модели для генерации эмбедингов предложений
- Классические классификаторы (LogReg, SVM, Random Forest) показывают высокую эффективность на текстовых признаках
- Гибкая настройка моделей с помощью Optuna (оптимизация гиперпараметров)

Pipeline обработки данных



Время классификации **100** групп ~ **60** секунд

Лучшая модель. Метрики

Модель эмбедингов	Классификатор	Ассигуру по кластерам
RoBERTa (ai-forever/ru-en-RoSBERTa)	Logistic Regression (оптимизированный параметр $C=0.01057$)	0.7015

Кластер	Precision	Recall	F1-score	Support
Гуманитарные науки	0.7027	0.8254	0.7591	63
Инженерное дело и технологии	0.7436	0.6744	0.7073	43
Искусство и культура	0.7080	0.7767	0.7407	103
Математика и естественные науки	0.6667	0.3200	0.4324	25
Медицина и здоровье	0.6842	0.8000	0.7376	65
Образование и педагогика	0.7692	0.6383	0.6977	47
Общие интересы	0.6750	0.6879	0.6814	157
Сельское хозяйство	0.8788	0.7838	0.8286	37
Социальные науки	0.5957	0.5283	0.5600	53

F1-score выше 0.7
для большинства
крупных классов,
что подтверждает
эффективность
подхода.

Лучшая
классификация:
"Сельское хозяйство"
Наиболее сложная:
"Математика и
естественные науки"

Оценка качества модели

Модель достигает **точности 70% (accuracy)** по крупным кластерам.


Наивысшее качество достигается в классах с большим количеством примеров.

Для менее представленных категорий точность ниже.

Для реальных задач такой уровень качества может быть достаточен, но мы видим потенциал для дальнейшего роста.

Возможности улучшения

Дообучение эмбеддингов и применение ансамблевых (ensemble) методов.




Архитектура системы

A man with a beard and dark hair, wearing a white long-sleeved shirt, is standing in profile and writing the word 'TELEGRAM' in capital letters on a white flipchart. He is holding a black marker in his right hand. The flipchart is on a stand, and the background is a plain, light-colored wall.

TELEGRAM

Workflow системы



Основные модули и технологический стек

Ключевые компоненты

- Парсер данных ВКонтакте — сбор информации о пользователях и группах через VK API, фильтрация и подготовка для анализа.
- ML-модуль — классификация групп по тематикам на основе текстового описания с помощью обученной модели, формирование профилей интересов пользователей.
- База данных — кэширование информации для ускорения работы и предотвращения повторного парсинга.
- Telegram-бот — пользовательский интерфейс: принимает ID, запускает анализ, возвращает результаты в PDF-отчете и таблице.

Стек технологий

Анализ данных



Хранение данных



Внешние API



VK API Telegram Bot
API

Инструменты разработки



2025



Интеграция и запуск сервиса

Интеграция компонентов

Все компоненты системы объединены в единый сервис

Обмен данными между модулями реализован через общую БД и API-запросы, что обеспечивает автоматическую обработку и быстрый отклик для пользователя.

Telegram-бот

Служит интерфейсом, принимает запросы и отправляет отчёты.

Парсер VK

Собирает данные о пользователях и группах через VK API.



База данных

Хранит результаты парсинга и профили пользователей для ускорения обработки.

ML-модуль

Анализирует текст и классифицирует группы по интересам.

VK API и парсер

Как работает парсер:

- На вход — до **3** VK ID
- Собираются группы, на которые подписаны пользователи
- Исключаются неактуальные или заблокированные сообщества
- Гибкая фильтрация (по дате, типу)



Время обработки
100 групп ~ 6 секунд


Технические детали:

- Обработка в батчах (по 100 групп)
- Параллельные запросы — масштабирование по числу VK API токенов
- Анализ каждой группы: проверка активности и контента на стене
- Все новые группы сохраняются в БД

Запуск и работа Telegram-бота



2025



ВЫВОДЫ и перспективы

Итоги проекта


Разработан и протестирован прототип сервиса профайлинга образовательных интересов пользователей ВКонтакте

Интеграция

Система объединяет VK-парсер, ML-модуль, базу данных и Telegram-бота в единую платформу.

Достижения

Возможна адаптация под другие платформы/социальные сети. Сервис успешно прошёл тестирование на реальных пользователях.



Качество

Модель показала точность ~70% по основным категориям, что достаточно для практического применения.

Перспективы и направления развития

Возможности развития

- Масштабирование сервиса для других соцсетей и платформ
- Добавление новых тематик и улучшение классификации
- Использование новых данных о пользователях: лайки, подписки, музыкальные предпочтения, друзья, геолокация
- Дообучение моделей на новых данных
- Расширение функционала Telegram-бота (персональные рекомендации, отчёты для организаций)


Применение

- Использование в HR-аналитике и образовании
- Персонализация онлайн-обучения
- Анализ трендов для платформ и учреждений

Возможные пути развития

- Тестирование на новых группах пользователей
- Запуск пилота с организациями
- Интеграция с внешними API и системами отчётности

Пример работы сервиса



Попробуй сам:



СПАСИБО!



ОСТАЛИСЬ ВОПРОСЫ?

Посмотрите подробную программу исследования



НАША КОМАНДА

Трухин Павел
Лещун Анастасия
Стребков Руслан
Черняк Екатерина
Сутормина Надежда

Аржановский Марк
Долгий Алексей
Патракова Екатерина
Никшин Никита
Макарова Наталья